

Parcial Final

NLP

RAG – Fichas de Datos de Seguridad

Cada grupo deberá implementar un sistema RAG (Recuperación Aumentada por Generación) orientado al análisis y consulta de documentos técnicos asociados a un fabricante de pinturas. El proyecto se enfoca en el diseño de un pipeline reproducible de procesamiento documental, priorizando la calidad de extracción, trazabilidad de la información, bajo costo computacional y mínima dependencia de servicios externos.

Asignación de fabricantes

El grupo puede consultarse en Moodle. Corresponde a la asignación que Moodle realiza de manera automática y que se ha utilizado durante todo el semestre.

Grupo	Fabricante asignado
Grupo A	CORONA
Grupo B	Pintuco
Grupo C	Pintuland
Grupo D	SIKA
Grupo E	CORONA
Grupo F	Pintuco
Grupo G	Pintuland
Grupo I	SIKA
Grupo J	CORONA

Requerimientos técnicos mínimos

- Implementar un pipeline de extracción documental capaz de convertir documentos PDF a formato Markdown (.md).
- Preservar la estructura original del documento: títulos, subtítulos, tablas, listas, notas y referencias cruzadas a imágenes o fuentes externas.
- Extraer e identificar la totalidad de las 16 secciones normativas presentes en el documento. Garantizar la fidelidad documental.
- Diseñar un sistema RAG funcional utilizando modelos locales o infraestructura propia.
- Implementar una estrategia de chunking documentada y justificable.
- Permitir consultas sobre el contenido documental de los documentos asignados.
- Garantizar trazabilidad entre la respuesta generada y el fragmento fuente recuperado.
- Documentar limitaciones, errores de extracción y estrategias de mitigación.

Tratamiento de imágenes y trazabilidad documental

- **Conversión de imagen a texto:** Los elementos visuales relevantes podrán ser procesados mediante OCR tradicional (por ejemplo, Tesseract) u otras metodologías de parsing documental compatibles con procesamiento local.
- **Asociación estructurada:** Cada imagen deberá asociarse a la tabla, sección o bloque técnico relacionado mediante proximidad espacial, referencias textuales o metadatos estructurales.
- **Trazabilidad:** Debajo de cada imagen en el archivo Markdown (.md), deberá incluirse un bloque de nota con la referencia estructurada correspondiente. Por ejemplo:

Nota de trazabilidad: La información numérica asociada a esta figura se encuentra en la Tabla 4 de la Sección 9.

- **Restricciones:** El flujo de trabajo no deberá depender de APIs pagas ni de servicios externos propietarios para la extracción principal del contenido documental.

Restricciones tecnológicas

- Evitar dependencias de APIs pagas.
- Priorizar herramientas open source.
- Se recomienda el uso de Ollama en entorno local o AWS.
- El proyecto deberá justificar las decisiones de arquitectura tomadas.
- Se evaluará la relación entre desempeño, costo computacional y complejidad operativa.

Evaluación del desempeño del RAG

Cada grupo deberá construir un conjunto de evaluación tipo ground truth basado en pares pregunta–respuesta generados a partir de los documentos procesados.

Se recomienda utilizar NotebookLM u otras herramientas equivalentes para generar preguntas y respuestas de referencia a partir del contenido documental original.

- Las preguntas deben cubrir múltiples secciones del documento.
- Deben incluir preguntas factuales, técnicas y de trazabilidad documental.
- Cada respuesta de referencia deberá indicar el fragmento fuente o sección utilizada.
- El grupo deberá comparar las respuestas generadas por el RAG frente al ground truth construido.

La comparación puede incluir criterios como:

- Exactitud semántica.
- Recuperación correcta del contexto.
- Coherencia técnica.
- Capacidad de trazabilidad.
- Alucinaciones o respuestas no sustentadas.

El informe final deberá incluir ejemplos comparativos entre la respuesta esperada y la respuesta generada por el sistema

Entregables

1. Repositorio del proyecto.
2. Documentación técnica del pipeline.
3. Arquitectura general del sistema.
4. Ejemplos de documentos convertidos a .md.
5. Demostración funcional del sistema RAG.
6. Informe corto describiendo decisiones técnicas, limitaciones y resultados.

Criterios de evaluación

Para la evaluación se tendrá en cuenta:

Criterio	Peso
Calidad del pipeline de extracción y conversión documental	20%
Fidelidad estructural del archivo .md generado	30%
Diseño de arquitectura y eficiencia técnica	20%
Implementación del sistema RAG	10%
Documentación técnica y presentación	20%

Para tener en cuenta:

- Se dará especial valor a las soluciones que mantengan una arquitectura reproducible, portable y con baja dependencia de infraestructura o servicios externos.
- Se permite el uso de herramientas como OpenCode, Claude Code o similares. La evaluación estará centrada en la comprensión de la arquitectura propuesta, la calidad técnica de las respuestas generadas, la trazabilidad documental y la reducción de dependencias innecesarias de servicios o infraestructura externa.